Pipeline Integrado de IA para Predição, Inferência Probabilística e Tomada de Decisão em Risco de Queimadas Ambientais

Trabalho Integrado de Fundamentos de Inteligência Artificial

Nathan V. A. Maciel John K. de A. Castro Victor S. V. de Souza
Heitor O. Rocha Lorenzo A. da C. Freitas

Instituto de Computação (ICOMP) – Universidade Federal do Amazonas (UFAM)
{nathan.maciel, john.castro, victor.souza, heitor.oliveira, lorenzo.freitas}@icomp.ufam.edu.br

Resumo

Este artigo apresenta a concepção, o equacionamento teórico e a avaliação de um pipeline modular de Inteligência Artificial em 6 etapas aplicadas ao monitoramento de risco de queimadas (Domínio P4: Meio Ambiente). O trabalho abrange: (1) indução simbólica por Árvores de Decisão com Entropia de Shannon e análise de não-monotonicidade; (2) aprendizado linear MNO, regularização Ridge (L_2) e Regressão Logística; (3) probabilidade axiomática com Teorema de Bayes; (4) Naive Bayes Gaussiano e algoritmo Expectation-Maximization (EM) para estimativa da variável oculta Z; (5) Redes Bayesianas via Grafo Acíclico Dirigido (DAG), inferência por enumeração exata e nós colisores; e (6) integração final com Sistema de Inferência Fuzzy de Mamdani. Os resultados validam que a tomada de decisão suave supera limiares rígidos em cenários ambíguos.

1 Introdução e Contextualização do Problema

1.1 Contexto do Domínio Ambiental (P4)

O bioma amazônico enfrenta desafios crescentes decorrentes do aumento de incêndios florestais. O monitoramento do risco de queimadas envolve o processamento de múltiplas variáveis meteorológicas caracterizadas por elevado ruído, não-linearidade e interdependência estocástica. Dias secos consecutivos, baixa umidade relativa, altas temperaturas e rajadas de vento atuam de forma combinada para favorecer a propagação do fogo.

1.2 Limitações de Sistemas Determinísticos Tradicionais

Sistemas tradicionais baseiam-se em limiares estáticos rígidos (ex.: emitir alerta se temperatura $> 35°$C e umidade $< 30\%$). Essa abordagem padece de rigidez operacional: pequenas oscilações de medição em torno do corte provocam descontinuidades bruscas. Uma medição de umidade de 30,1% pode classificar uma região como segura, enquanto 29,9% dispara alerta de emergência. A Inteligência Artificial unifica aprendizado simbólico, estatístico, probabilístico e nebuloso para solucionar esse problema.

1.3 Visão Geral do Pipeline em 6 Etapas

Desenvolveu-se um pipeline composto por 6 etapas na disciplina de Fundamentos de IA (ICOMP/UFAM):

1. **Aprendizado Simbólico:** Indução de Árvores de Decisão e análise de não-monotonicidade.
2. **Aprendizado Linear:** Regressão MNO, Gradiente Descendente com Ridge (L_2) e Regressão Logística.

3. **Modelagem Probabilística:** Distribuições conjuntas, Regra da Cadeia e Teorema de Bayes.
4. **Aprendizado com Variáveis Ocultas:** Estimadores MLE/MAP, Naive Bayes e Algoritmo EM.
5. **Grafos Bayesianos:** Redes Bayesianas, inferência exata, d-separação e nós colisores.
6. **Decisão Nebulosa:** Sistema Fuzzy de Mamdani para tomada de decisão suave.

—

2 Metodologia e Dataset

2.1 Estrutura do Repositório

O projeto é modularizado no PyCharm/Jupyter: `/data` (datasets CSV), `/notebooks` (notebooks das etapas 1 a 6), `/src` (`utils.py`, `em.py`, `fuzzy.py`) e `/docs` (`relatorio_final.tex`).

2.2 Sintetização dos Dados Meteorológicos

Desenvolveu-se o gerador estocástico `gerar_dados_sinteticos_queimadas` ($N = 1000$ amostras) simulando as estações do INMET/INPE na Amazônia Legal (Tabela 1).

Tabela 1: Atributos meteorológicos e ambientais do dataset sintético ($N = 1000$).

Atributo	**Tipo**	**Descrição e Unidade de Medida**
`dias_sem_chuva`	Contínuo	Estiagem consecutiva em dias (d)
`precipitacao`	Contínuo	Volume de chuva acumulado (mm)
`temperatura_max`	Contínuo	Temperatura máxima diária (°C)
`umidade_relativa`	Contínuo	Umidade relativa do ar (%)
`velocidade_vento`	Contínuo	Velocidade média do vento (km/h)
`risco_fogo`	Contínuo	Score de risco ambiental $[0.0, 1.0]$
`risco_critico`	Binário	Emergência (1 se risco $\geq 0,8$, 0 c.c.)

2.3 Padronização e Protocolo de Validação

Para algoritmos sensíveis à escala, aplicou-se Z-score: $z = \frac{x-\mu}{\sigma}$. Todos os testes classificatórios utilizaram **Validação Cruzada 5-Fold** com semente fixada (`seed=42`).

—

3 Etapa 1: Indução de Árvores de Decisão

3.1 O que foi feito

Implementou-se do zero o algoritmo `LEARN-DECISION-TREE` na classe `DecisionTreeFromScratch`. A seleção de atributos utiliza a Entropia de Shannon $H(S)$ e o Ganho de Informação $IG(S, A, \theta)$:

$$H(S) = -\sum_{i=1}^{k} p_i \log_2(p_i) \tag{1}$$

$$IG(S, A, \theta) = H(S) - \left(\frac{|S_{esq}|}{|S|} H(S_{esq}) + \frac{|S_{dir}|}{|S|} H(S_{dir}) \right) \tag{2}$$

A árvore customizada ($max_depth = 4$, $min_samples_split = 5$) foi comparada com o `scikit-learn` via 5-Fold CV (Tabela 2).

Tabela 2: Desempenho da Árvore de Decisão (Validação Cruzada 5-Fold).

Modelo	**Treino (Média)**	**Teste (5-Fold CV)**
Árvore Customizada (`Scratch`)	$88{,}50\% \pm 0{,}8\%$	$82{,}10\% \pm 1{,}2\%$
`Scikit-Learn Tree`	$89{,}10\% \pm 0{,}6\%$	$83{,}40\% \pm 1{,}1\%$

3.2 Por que foi feito

A indução de árvores fornece um paradigma simbólico de alta interpretabilidade. Equipes de gestão ambiental necessitam de regras explícitas do tipo `SE-ENTÃO` para justificar decisões e alocação de recursos.

3.3 O que foi aprendido e Análise de Não-Monotonicidade

Comprovou-se a equivalência estatística frente ao `scikit-learn` (82,10% vs. 83,40%). Demonstrou-se a **Lógica Não-Monotônica**: na lógica clássica dedutiva (monotônica), $K \vdash \alpha \implies (K \cup B) \vdash \alpha$. No aprendizado indutivo, contudo, novas amostras alteram $H(S)$ e os limiares θ^*, podendo invalidar ou reestruturar regras de decisão anteriormente aprendidas.

—

4 Etapa 2: Aprendizado Linear e Logístico

4.1 O que foi feito

Ajustou-se a Regressão Linear Univariada MNO entre $x =$ `dias_sem_chuva` e $y =$ `risco_fogo`:

$$w_1 = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sum(x_i - \bar{x})^2}, \quad w_0 = \bar{y} - w_1\bar{x} \tag{3}$$

resultando em risco $= 0{,}2145 + 0{,}0285 \cdot d$ ($R^2 = 0{,}6420$). Na regressão multivariada $X \in \mathbb{R}^{N \times d}$, adicionou-se **Regularização Ridge (L_2)** minimizada via Gradiente Descendente:

$$J(w, b) = \frac{1}{2N} \sum_{i=1}^{N} (\hat{y}^{(i)} - y^{(i)})^2 + \frac{\lambda}{2N} \|w\|_2^2 \tag{4}$$

O R^2 alcançou 0,8120. Para a classificação binária de `risco_critico`, a Regressão Logística com sigmóide $\sigma(z) = \frac{1}{1+e^{-z}}$ e Entropia Cruzada atingiu 85,20% de acurácia (85,40% no `scikit-learn`).

4.2 Por que foi feito

O aprendizado linear quantifica relações funcionais contínuas do risco ambiental. A regularização Ridge (L_2) foi introduzida para suavizar os pesos diante da multicolinearidade entre temperatura e umidade.

4.3 O que foi aprendido

Verificou-se a necessidade da padronização Z-score para garantir estabilidade no Gradiente Descendente. A Regressão Logística provou ser um baseline classificatório robusto, superando a Árvore de Decisão em acurácia.

—

5 Etapa 3: Teoria da Probabilidade Aplicada

5.1 O que foi feito

Estimou-se a Distribuição Conjunta $P(A, B)$ sobre $A =$ `alta_temp` ($\geq 32°$C) e $B =$ `baixa_umid` ($\leq 45\%$) (Tabela 3).

Tabela 3: Tabela de Distribuição Conjunta Empírica $P(\text{Alta_Temp}, \text{Baixa_Umid})$.

	$B = 0$ (Umid $> 45\%$)	$B = 1$ (Umid $\leq 45\%$)	**Total Marginal** $P(A)$
$A = 0$	0,3810	0,1420	0,5230
$A = 1$	0,1150	0,3620	0,4770
Total Marginal $P(B)$	0,4960	0,5040	**1,0000**

A soma das probabilidades atômicas satisfaz os Axiomas de Kolmogorov ($\sum P = 1{,}0000$). Calculou-se $P(A = 1 \mid B = 1) = \frac{0{,}3620}{0{,}5040} = 0{,}7183$, comprovou-se a Regra da Cadeia $P(A, B, C) = P(A)P(B \mid A)P(C \mid A, B) = 0{,}2465$ e realizou-se a inferência diagnóstica via Teorema de Bayes:

$$P(R = 1 \mid B = 1) = \frac{P(B = 1 \mid R = 1)P(R = 1)}{P(B = 1)} = \frac{0{,}8545 \times 0{,}2200}{0{,}5040} = 0{,}3730 \tag{5}$$

5.2 Por que foi feito

A etapa fundamentou o raciocínio formal sob incerteza, garantindo que o modelo de atualização de crenças respeite rigorosamente as leis axiomáticas da probabilidade.

5.3 O que foi aprendido

A probabilidade condicional $P(A = 1 \mid B = 1) = 0{,}7183$ mostrou-se muito superior à marginal $P(A = 1) = 0{,}4770$, confirmando numericamente a forte dependência estocástica entre secas e altas temperaturas.

—

6 Etapa 4: Aprendizado Probabilístico e EM

6.1 O que foi feito

Implementou-se o Naive Bayes Gaussiano e compararam-se os estimadores MLE ($\theta_{MLE} = 0{,}5040$) e MAP com prior $Beta(2, 2)$ ($\theta_{MAP} = 0{,}5040$). Para contornar a suposição de independência condicional do Naive Bayes, desenvolveu-se o **Algoritmo Expectation-Maximization (EM)** para Misturas de Gaussianas (`src/em.py`), inferindo uma **variável oculta $Z \in \{0, 1\}$** ($K = 2$ regimes microclimáticos).

O algoritmo EM alterna entre o Passo-E ($\gamma_{ik} = \frac{\pi_k \mathcal{N}(x_i|\mu_k, \Sigma_k)}{\sum \pi_j \mathcal{N}(x_i|\mu_j, \Sigma_j)}$) e o Passo-M (atualização de π_k, μ_k, Σ_k). A Log-Verossimilhança convergiu monotonicamente ao longo das iterações. A inclusão de Z aprimorou o Naive Bayes (Tabela 4).

Tabela 4: Desempenho da Classificação Probabilística (5-Fold CV).

Modelo Classificador	**Acurácia Média no Teste (5-Fold CV)**
Naive Bayes Gaussiano Puro	$79{,}20\% \pm 1{,}4\%$
Naive Bayes + Variável Oculta Z (Inferida via EM)	**84,80% ± 1,0%**

6.2 Por que foi feito

Fatores climáticos não-observados geram dependências complexas. O algoritmo EM descobre clusters latentes sem necessidade de rótulos manuais, enriquecendo o espaço de atributos.

6.3 O que foi aprendido

A inclusão de Z elevou a acurácia de 79,20% para 84,80%, comprovando que inferir variáveis ocultas reduz a violação da suposição de independência condicional do Naive Bayes.

—

7 Etapa 5: Redes Bayesianas e Inferência Exata

7.1 O que foi feito

Construiu-se uma Rede Bayesiana com 5 nós: DiasSemChuva(D), Temperatura(T), Umidade(U), RiscoFogo(R) e FocoQueimada(F). A fatoração é $P(D,T,U,R,F) = P(D)P(T)P(U)P(R \mid D,T,U)P(F \mid R)$. Implementou-se o algoritmo `INFERENCE-BY-ENUMERATION` na classe `EnumerationInference` ($P(X \mid e) = \alpha \sum_y P(X,e,y)$), obtendo paridade com o `pgmpy` (Tabela 5).

Tabela 5: Consulta de Inferência Exata $P(\text{Foco} = 1 \mid \text{DiasSemChuva} = 1, \text{Umidade} = 1)$.

Método de Inferência	**Resultado Calculado**
Enumeração Manual (`Scratch`)	0,8241
`pgmpy` (Variable Elimination)	0,8241

Demonstrou-se o efeito do **Nó Colisor** ($T \to R \leftarrow U$): sem observar R, T e U são independentes ($P(U = 1 \mid T = 0) = 0{,}5021 \approx P(U = 1 \mid T = 1) = 0{,}5060$). Ao observar $R = 1$, abre-se o caminho de d-separação (*explaining away*): $P(U = 1 \mid T = 0, R = 1) = 0{,}8910 \neq P(U = 1 \mid T = 1, R = 1) = 0{,}6420$. A Rede Bayesiana exigiu apenas 13 parâmetros nas CPTs contra 31 da tabela conjunta completa (**economia de 58,06%**).

7.2 Por que foi feito

Redes Bayesianas codificam relações de causa e efeito em Grafos Acíclicos Dirigidos (DAGs), permitindo inferências causais e preditivas eficientes.

7.3 O que foi aprendido

A comprovação do efeito *explaining away* e a redução de 58% na complexidade de parâmetros demonstraram a viabilidade prática de modelos gráficos probabilísticos.

—

8 Etapa 6: Sistema Fuzzy e Integração Final

8.1 O que foi feito

Desenvolveu-se o Sistema Fuzzy de Mamdani em `src/fuzzy.py`, combinando $P_{Bayes}(Foco \mid e) \in [0,1]$ e a velocidade do vento $V \in [0,50]$ km/h para determinar o Nível de Alerta Ambiental ($A \in [0,100\%]$). As variáveis utilizam pertinência triangular e defuzzificação pelo Método do Centroide: $z^* = \frac{\int z\mu(z)dz}{\int \mu(z)dz}$. O pipeline integrado foi testado em 4 cenários (Tabela 6).

Tabela 6: Resultados da Integração do Pipeline: Decisão Suave vs. Limiar Rígido.

Cenário Ambiental de Teste	P_{Bayes}	**Vento (km/h)**	**Alerta Fuzzy (%)**	**Decisão Rígida (0,5)**
1. Seca Severa + Vento Forte	0,8241	42,0	**88,42%**	ALERTA CRÍTICO
2. Seca Moderada + Vento Moderado	0,6120	22,0	**54,15%**	ALERTA CRÍTICO
3. Condições Úmidas + Vento Fraco	0,0840	8,0	**18,30%**	NORMAL
4. Fronteira Ambígua (Alta Temp, Umid Normal)	0,4410	32,0	**55,80%**	NORMAL (Falha Rígida)

8.2 Por que foi feito

Sistemas de decisão baseados em limiares rígidos ($P \geq 0{,}5$) sofrem de descontinuidade operacional. A lógica Fuzzy introduz pertinência contínua, unindo probabilidade estocástica e vaguidade linguística.

8.3 O que foi aprendido e Análise de Decisão Suave

No Cenário 4, o limiar rígido falha ao emitir alerta `NORMAL` ($P_{Bayes} = 0{,}4410$), ignorando ventos fortes (32 km/h). O sistema Fuzzy emite um **Alerta Intermediário de 55,80%**, comprovando a superioridade da tomada de decisão suave.

—

9 Discussão Geral e Conclusão

O projeto integrou quatro paradigmas fundamentais de IA: aprendizado simbólico (árvores interpretáveis, não-monotônicas), modelos lineares/logísticos (85,20% acurácia), probabilidade bayesiana/causal (algoritmo EM aumentando acurácia para 84,80% e economia de 58% de parâmetros) e lógica nebulosa de Mamdani.

A integração da Rede Bayesiana com o sistema Fuzzy eliminou as falhas dos limiares determinísticos rígidos, garantindo um sistema preciso, interpretável e seguro para apoio à decisão de gestão ambiental na Amazônia.

Referências

[1] RUSSELL, S.; NORVIG, P. **Inteligência Artificial: uma abordagem moderna**. 4. ed. Rio de Janeiro: GEN LTC, 2022.

[2] INPE. **Programa Queimadas: Monitoramento por Satélite**. Disponível em: `https://queimadas.dpm.inpe.br/`. Acesso em: 2026.

[3] INMET. **Banco de Dados Meteorológicos (BDMEP)**. Disponível em: `https://bdmep.inmet.gov.br/`. Acesso em: 2026.

[4] KOLLER, D.; FRIEDMAN, N. **Probabilistic Graphical Models**. MIT Press, 2009.

[5] DUDA, R. O.; HART, P. E.; STORK, D. G. **Pattern Classification**. 2. ed. Wiley, 2000.

[6] ZADEH, L. A. Fuzzy sets. **Information and Control**, v. 8, p. 338-353, 1965.